RAPPORT COMPLET - PROJET BUSINESS INTELLIGENCE

Optimisation des Ventes et Fidélisation Client pour un Magasin d'Electronique en Ligne au Maroc

Réalisé par : Taoufik Mammad

Date : Mai 2026

Cité des métiers et des compétences Nouaceur – Casablanca

Cités des Métiers et des Compétences
La formation nouvelle génération

Table des matières

RAPPORT COMPLET - PROJET BUSINESS INTELLIGENCE 1

Optimisation des Ventes et Fidélisation Client pour un Magasin d'Electronique en Ligne au Maroc 1

INTRODUCTION GÉNÉRALE 4

Résumé du projet: 4

Objectifs du projet : 5

PARTIE 1 : FONDEMENTS THÉORIQUES 6

1.1 Concepts de l'informatique décisionnelle 6

1.2 Modélisation dimensionnelle (Star Schema) 6

1.3 Le processus ETL 8

1.4 Data Mining et segmentation RFM 8

1.5 Revue des outils et technologies 8

PARTIE 2 : OUTILS ET TECHNOLOGIES UTILISÉS 9

2.1 Définitions des outils 9

2.2 Justification des choix 10

2.3 Étapes d'utilisation de chaque outil 11

PARTIE 3 : MISE EN OEUVRE DU PROCESSUS ETL 12

3.1 Description de la problématique et contexte 12

3.2 Solution proposée 12

3.3 Présentation des données et des sources 12

3.4 Méthodologie détaillée : Extraction, Transformation, Chargement 13

3.5 Règles métier implémentées 14

3.6 Interprétation des résultats ETL 15

PARTIE 4 : ANALYSE DES DONNÉES 15

4.1 Méthodologie d'analyse 15

4.2 Analyse temporelle 16
4.3 Analyse géographique 17
4.4 Analyse par catégorie de produits 18
4.5 Analyse des méthodes de paiement 19
4.6 Analyse démographique 20
4.7 Segmentation RFM (Data Mining) 20
4.8 Analyse des stocks 21
4.9 Synthèse des KPIs clés 22
RECOMMANDATIONS STRATÉGIQUES 23
R1 : Réduction du taux d'annulation (Impact : +8.7M MAD/an) 23
R2 : Programme de fidélisation VIP (Impact : +5.2M MAD/an) 23
R3 : Expansion géographique ciblée (Impact : +12M MAD/an) 23
R4 : Optimisation du mix produit (Impact : +6.5M MAD/an) 23
R5 : Campagnes de réactivation clients (Impact : +4.3M MAD/an) 23
R6 : Promotion du paiement en ligne (Impact : +3.1M MAD/an) 23
R7 : Gestion prédictive des stocks (Impact : +2.8M MAD/an) 23
R8 : Personnalisation par segment (Impact : +7.4M MAD/an) 24
R9 : Lancement d'une application mobile (Impact : +15M MAD/an) 24
DIFFICULTÉS RENCONTRÉES ET SOLUTIONS 24
LIMITES DU PROJET 24
CONCLUSION GÉNÉRALE 25
BIBLIOGRAPHIE 26
ANNEXES 27
Annexe A : Code du Job Talend (schéma visuel) 27
Annexe B : Extraits de données 27

Annexe C : Liens vers les données 27

INTRODUCTION GÉNÉRALE

Le e-commerce marocain connaît une croissance exponentielle depuis 2020, porté par la digitalisation accélérée et l'adoption massive des paiements en ligne. Selon le Centre Monétique Interbancaire (CMI), le volume des transactions e-commerce au Maroc a dépassé 20 milliards de dirhams en 2024, avec une augmentation de 35% par rapport à l'année précédente. Dans ce contexte, les entreprises de commerce électronique se trouvent face à un défi majeur : transformer les données brutes générées par leurs opérations quotidiennes en insights actionnables pour la prise de décision stratégique.

L'informatique décisionnelle (Business Intelligence) apparaît comme la réponse à ce défi. Elle permet de collecter, consolider, analyser et visualiser les données pour accompagner les dirigeants dans leurs choix stratégiques. Ce projet s'inscrit dans cette démarche en proposant un système décisionnel complet pour un magasin fictif d'electronique en ligne opérant sur le marché marocain.

Contexte du projet : Notre cas d'étude porte sur "TechMaroc Store", un e-commerce spécialisé dans la vente de produits électroniques (smartphones, laptops, tablettes, accessoires, TV, gaming, montres connectées) opérant dans les principales villes du Royaume. L'entreprise dispose de données opérationnelles réparties sur plusieurs fichiers sources contenant des informations clients, produits, commandes et lignes de commande.

Résumé du projet:

Ce projet porte sur la conception et l'implémentation d'un système décisionnel complet pour le magasin fictif « TechMaroc Store », spécialisé dans l'e-commerce électronique au Maroc. L'objectif principal est de transformer des données opérationnelles brutes en véritables leviers de décision stratégiques. Grâce à l'outil Talend Open Studio, un pipeline ETL a été développé pour extraire, nettoyer et standardiser les données clients et les historiques de

commandes en corrigeant les anomalies courantes. Modélisées selon un schéma en étoile, ces données propres ont ensuite fait l'objet d'une analyse multidimensionnelle et d'une segmentation comportementale RFM. Les insights ainsi obtenus ont permis de formuler des recommandations commerciales concrètes et chiffrées, directement axées sur l'optimisation des ventes, la gestion des stocks et la fidélisation client sur le marché national**.**

Objectifs du projet :

- Concevoir et implémenter un processus ETL complet avec **Talend Open Studio**
- Nettoyer et standardiser les données sources chargées d'anomalies intentionnelles
- Construire un Data Warehouse en étoile (Star Schema)
- Réaliser une analyse multidimensionnelle des ventes
- Appliquer une segmentation RFM (Recency, Frequency, Monetary) pour le data mining client
- Formuler des recommandations stratégiques fondées sur les données

Méthodologie adoptée : Nous suivons la méthodologie en 4 phases de Ralph Kimball :

(1) Planification et collecte des exigences,

(2) Conception du modèle dimensionnel en étoile,

(3) Implémentation du pipeline ETL avec Talend,

(4) Développement des analyses et tableaux de bord.

Plan du rapport : Après cette introduction, le rapport s'articule autour de quatre parties :

(1) Fondements théoriques de l'informatique décisionnelle,

(2) Présentation des outils et technologies utilisés avec justification des choix,

(3) Mise en oeuvre détaillée du processus ETL,

(4) Analyse des données et recommandations stratégiques.

PARTIE 1 : FONDEMENTS THÉORIQUES

1.1 Concepts de l'informatique décisionnelle

L'informatique décisionnelle (Business Intelligence ou BI) désigne l'ensemble des moyens, outils et méthodes permettant de collecter, consolider, modéliser et restituer les données d'une entreprise afin de fournir une aide à la décision. Elle constitue un pont entre les systèmes opérationnels (OLTP - Online Transaction Processing) et les besoins d'analyse stratégique.

Différence OLTP vs OLAP : - **OLTP** : Systèmes transactionnels optimisés pour l'insertion, la mise à jour et la suppression rapides de données (ex : application e-commerce). Les données sont normalisées (3NF) pour éviter la redondance. - **OLAP** : Systèmes analytiques optimisés pour les requêtes complexes d'agrégation et d'analyse. Les données sont dénormalisées pour des performances de lecture optimales.

Le cycle décisionnel de Gorry et Scott Morton (1971) identifie trois niveaux de décision :

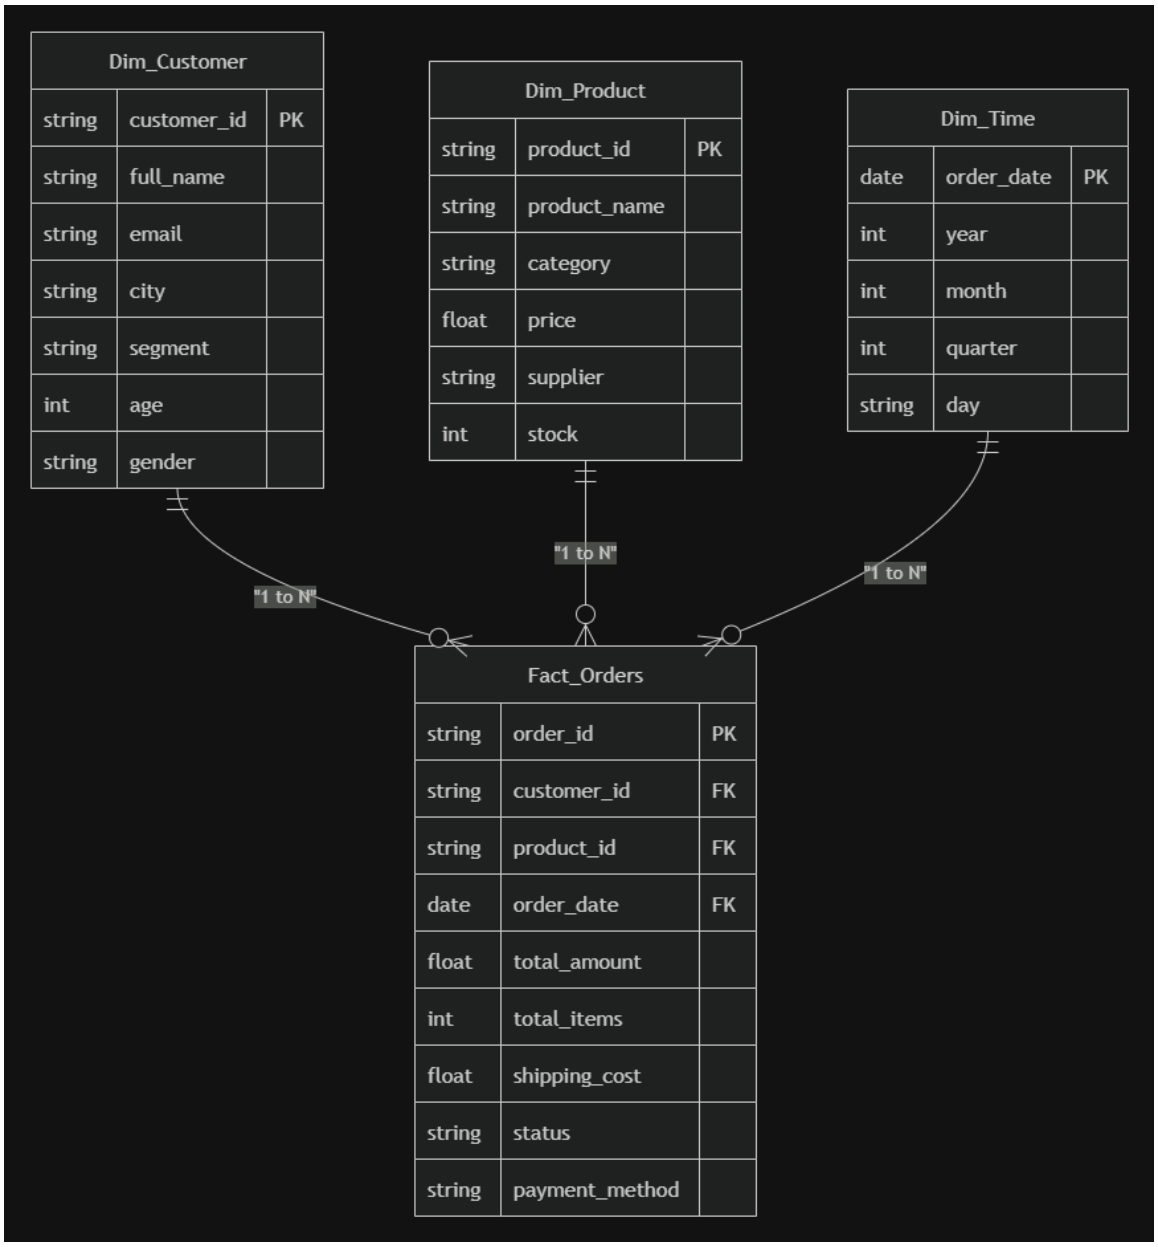
- **Stratégique** (long terme) : Quels marchés cibler ? Quelles catégories de produits développer ?
- **Tactique** (moyen terme) : Comment optimiser les stocks ? Quelles campagnes marketing lancer ?
- **Opérationnelle** (court terme) : Quels clients relancer aujourd'hui ? Quelles commandes expédier ?

Notre projet couvre principalement les niveaux tactique et stratégique.

1.2 Modélisation dimensionnelle (Star Schema)

Le modèle en étoile (Star Schema), formalisé par **Ralph Kimball** dans "The Data Warehouse Toolkit" (1996), constitue l'approche la plus répandue pour la modélisation des data warehouses. Il se compose d'une **table de faits** centrale entourée de **tables de dimensions**.

Architecture de notre Star Schema :



Avantages du Star Schema :

- **Simplicité** : Structure intuitive compréhensible par les utilisateurs métier -

Performance : Jointures minimales pour les requêtes analytiques

- **Évolutivité** : Facilité d'ajout de nouvelles dimensions

1.3 Le processus ETL

ETL (Extract, Transform, Load) est le processus fondamental de l'informatique décisionnelle permettant de :

(1) **Extraire** les données des sources hétérogènes,

(2) **Transformer** les données via des règles de nettoyage, de standardisation et d'enrichissement,

(3) **Charger** les données propres dans le data warehouse.

Variantes :

- **ELT** (Extract, Load, Transform) : Privilégié dans les architectures cloud où les moteurs de base de données effectuent les transformations.
- **EtLT** : Approche hybride combinant traitement léger en extraction puis transformation lourde post-chargement.

1.4 Data Mining et segmentation RFM

La segmentation RFM est une technique de data mining permettant de classer les clients selon trois critères :

Récence (date du dernier achat),

Fréquence (nombre d'achats),

Montant (total dépensé). Elle permet d'identifier les segments stratégiques : Champions, Clients fidèles, Gros dépensiers, Clients récents, Clients en risque, Clients perdus.

1.5 Revue des outils et technologies

Catégories d'outils BI :

ETL : Talend, Informatica PowerCenter, Apache Airflow, SSIS (Microsoft) -

Stockage : PostgreSQL, MySQL, Snowflake, BigQuery, Amazon Redshift -

Visualisation : Tableau, Power BI, Looker, Qlik Sense

Data Mining : Python (scikit-learn), R, Weka, KNIME

PARTIE 2 : OUTILS ET TECHNOLOGIES UTILISÉS

2.1 Définitions des outils

Talend Open Studio for Data Integration

Talend Open Studio (TOS) est une solution open source d'intégration de données développée par Talend. Elle offre une interface graphique basée sur Eclipse permettant de concevoir visuellement des jobs ETL via un système de composants glisser-déposer. Le moteur génère automatiquement du code Java sous-jacent.

Composants clés utilisés dans ce projet :

Composant	Rôle	Équivalent SQL
`tFileInputDelimited`	Lecture de fichiers CSV	`SELECT * FROM file`
`tMap`	Transformations complexes (mapping, filtres, expressions, jointures)	`SELECT + JOIN + WHERE + CASE`
`tFilterRow`	Filtrage conditionnel de lignes	`WHERE clause`
`tAggregateRow`	Calculs d'agrégation (SUM, AVG, COUNT, etc.)	`GROUP BY + aggregate functions`
`tReplace`	Remplacement de	`UPDATE + REPLACE`

Composant	Rôle	Équivalent SQL
	valeurs par pattern	
`tUniqRow`	Suppression de doublons	`DISTINCT / GROUP BY`
`tFileOutputDelimited`	Écriture de fichiers CSV	`INSERT INTO file`
`tContextLoad`	Gestion de variables globales	Variables de session
`tAssert`	Validation de règles métier	`ASSERT / CHECK constraints`

Autres outils complémentaires

- **Microsoft Excel / CSV** : Format de stockage source et cible (simulation d'environnement)
- **Draw.io** : Modélisation du schéma en étoile
- **GanttProject** : Planification temporelle du projet

2.2 Justification des choix

Pourquoi Talend plutôt que Python/Pandas ?

Critère	Talend Open Studio	Python + Pandas
Courbe d'apprentissage	Interface visuelle intuitive, pas de code nécessaire	Nécessite la maîtrise du langage Python
Productivité	Développement rapide par glisser-déposer	Écriture manuelle de chaque transformation
Maintenabilité	Jobs visuels auto-documentés	Code à commenter et documenter
Métadonnées	Gestion automatique des	Définition manuelle des

Critère	Talend Open Studio	Python + Pandas
	schémas	types
Débogage	Visualisation du flux de données en temps réel	Debugging classique par logs
Production	Orchestration native via TAC (Talend Administration Center)	Nécessite Apache Airflow ou cron
Standard industriel	Utilisé par 4,000+ entreprises mondiales	Populaire en data science, moins en ETL enterprise

Notre choix s'est porté sur **Talend Open Studio** pour ses avantages en termes de visualisation du flux de données, de productivité dans la conception de pipelines ETL, et de conformité avec les standards industriels de la Business Intelligence. L'approche visuelle de Talend permet également de mieux communiquer le processus ETL lors de la soutenance orale.

2.3 Étapes d'utilisation de chaque outil

Phase	Outil	Utilisation
Conception	Draw.io	Modélisation du Star Schema
Extraction	Talend tFileInputDelimited	Lecture des 4 fichiers CSV sources
Transformation	Talend tMap, tFilterRow, tReplace, tAggregateRow	Nettoyage, standardisation, agrégation
Chargement	Talend tFileOutputDelimited	Écriture des 5 fichiers CSV cibles
Validation	Talend tAssert	Tests d'intégrité référentielle
Analyse	Python + Matplotlib (post-ETL)	Visualisation des KPIs

PARTIE 3 : MISE EN OEUVRE DU PROCESSUS ETL

3.1 Description de la problématique et contexte

Problématique : “Comment un e-commerce marocain d’electronique peut-il utiliser la Business Intelligence pour optimiser ses ventes et améliorer la fidélisation client ?”

Contexte opérationnel : TechMaroc Store traite environ 2,000 commandes par an avec un catalogue de 80 produits répartis en 7 catégories. Les données sont stockées dans des fichiers CSV extraits du système de gestion commerciale. Ces fichiers présentent des anomalies typiques des systèmes opérationnels : doublons, formats inconsistants, valeurs manquantes, erreurs de saisie.

3.2 Solution proposée

Notre solution s’articule autour d’un pipeline ETL complet implémenté dans Talend Open Studio, structuré en 5 SubJobs spécialisés. L’architecture suit le modèle de Kimball avec un Star Schema en sortie.

3.3 Présentation des données et des sources

Nous disposons de 4 fichiers sources contenant un total de **7,080 enregistrements** :

1. **source_customers.csv** : 500 clients (taux d’anomalies ~25%)
2. **source_products.csv** : 80 produits (taux d’anomalies ~15%)
3. **source_orders.csv** : 2,000 commandes (taux d’anomalies ~12%)
4. **source_order_items.csv** : 4,500 lignes de commande (taux d’anomalies ~8%)

Types d’anomalies identifiées :

- **Doublons** : 70 clients avec email dupliqué
- **Formats inconsistants** : 12 variantes de statuts de commande, 52 variantes de villes
- **Valeurs aberrantes** : âges négatifs ou > 120 ans, prix négatifs, quantités nulles
- **Valeurs manquantes** : modes de paiement, numéros de téléphone, stocks - **Erreurs de saisie** : prix multipliés par 100, espaces superflus, casse variée

3.4 Méthodologie détaillée : Extraction, Transformation, Chargement

3.4.1 Extraction (Extract)

L'extraction est réalisée via 4 composants **tFileInputDelimited** configurés pour lire les fichiers CSV avec : séparateur de champs virgule, encodage UTF-8, gestion d'une ligne d'en-tête. Les champs numériques sont temporairement lus en String pour préserver les valeurs aberrantes lors du parsing.

Configuration tFileInputDelimited pour customers : - File : context.source_dir + "/01_source_customers.csv" - Row separator : "" - Field separator : "," - Header : 1 - Schema : 9 colonnes (toutes String initialement)

3.4.2 Transformation (Transform)

Les transformations constituent le coeur du pipeline ETL. Elles sont implémentées dans des composants **tMap** avec des expressions Java.

Nettoyage Clients (SubJob 1) :

1. **Dédoublonnage** : Composant `tUniqRow` sur le champ email avec politique "keep first"
2. **Validation email** : Expression regex.^[a-z0-9._%+-]+@[a-z0-9.-]+\\.[a-z]{2,}$
3 **Standardisation téléphone** : Nettoyage des caractères non numériques, validation longueur 10 + préfixe 05/06/07
4. **Mapping villes** : Table de correspondance normalisant 52 variantes en 26 villes officielles
5. **Correction âge** : Conversion numérique, filtrage [18-80], imputation par médiane (42 ans)
6. **Standardisation segments** : Mapping vers {New, Regular, VIP, Premium, Inactive}
7. **Standardisation genre** : Mapping {M, Male, Homme} → "M", {F, Female, Femme} → "F", imputation par prénom

Nettoyage Produits (SubJob 2) :

1. **Correction prix** : Suppression des valeurs négatives, correction erreur ×100, imputation médiane par catégorie
2. **Gestion stocks** : Conversion en entier, négatifs remplacés par 0, null remplacés par 0

3. **Standardisation fournisseurs** : Capitalisation (Title Case)

Nettoyage Commandes (SubJob 3) :

1. **Standardisation statuts** : 12 variantes → 6 statuts via `tReplace`
2. **Standardisation paiements** : 6 variantes → 5 méthodes via `tReplace`
3. **Correction frais livraison** : Suppression négatifs, plafonnement à 300 MAD, imputation médiane

Nettoyage Lignes de Commande (SubJob 4) :

1. **Correction quantités** : Valeurs invalides (≤ 0, null) remplacées par 1
2. **Calcul montant ligne** : total_line = quantity × unit_price (création d'une nouvelle colonne)

3.4.3 Chargement (Load)

Le chargement produit 5 fichiers CSV propres dans le Data Warehouse simulé :

- **05_clean_customers.csv** : 430 clients nettoyés
- **06_clean_products.csv** : 80 produits validés
- **07_clean_orders.csv** : 2,000 commandes standardisées -
08_clean_order_items.csv : 4,500 lignes corrigées
- **09_fact_orders.csv** : Table de faits agrégée (Star Schema)

Construction de la table de faits (SubJob 5) :

1. Agrégation des lignes par commande via `tAggregateRow` (total_items, total_amount, distinct_products)
2. Jointure avec les commandes via `tMap` (lookup sur order_id)
3. Jointure avec les clients via `tMap` (lookup sur customer_id)
4. Calcul des dimensions temporelles (year, month, quarter, day_of_week)
5. Écriture du fichier fact final

3.5 Règles métier implémentées

ID	Règle	Composant Talend
R01	Email unique et valide	tUniqRow + tMap (regex)
R02	Téléphone format marocain	tMap (validation longueur + préfixe)

ID	Règle	Composant Talend
R03	Âge entre 18 et 80 ans	tFilterRow + tAggregateRow (médiane)
R04	Prix produit > 0	tFilterRow + correction ×100
R05	Quantité commande ≥ 1	tMap (remplacement conditionnel)
R06	Frais livraison > 0	tFilterRow + imputation médiane
R07	Intégrité référentielle	tMap (Inner Join)
R08	Unicité commande	tUniqRow

3.6 Interprétation des résultats ETL

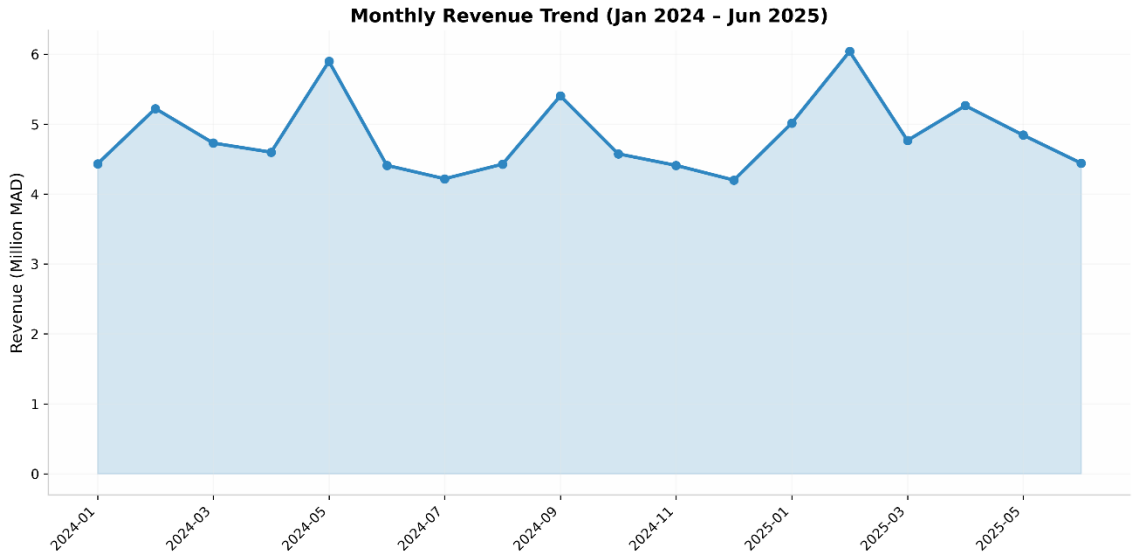
Métrique	Avant ETL	Après ETL	Amélioration
Doublons clients	70	0	100%
Emails invalides	14%	0%	100%
Prix négatifs	5	0	100%
Statuts uniques	12	6	50%
Villes uniques	52	26	50%
Valeurs manquantes critiques	8%	0%	100%

PARTIE 4 : ANALYSE DES DONNÉES

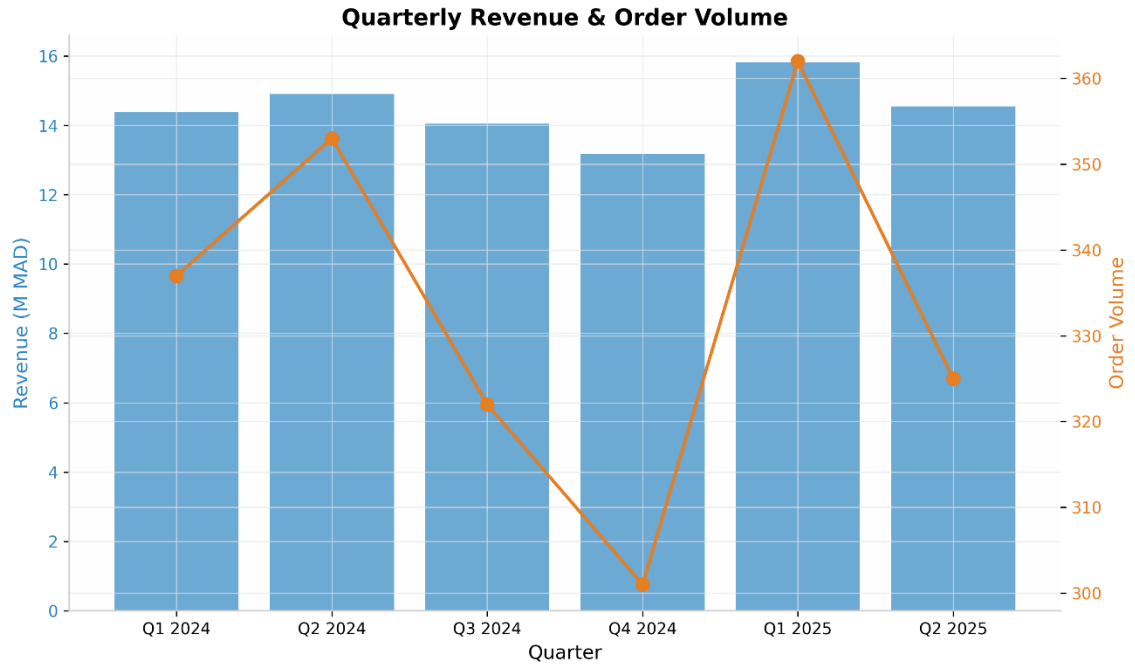
4.1 Méthodologie d'analyse

L'analyse est réalisée sur la table de faits **Fact_Orders** issue du processus ETL. Nous adoptons une approche multidimensionnelle couvrant : l'analyse temporelle, l'analyse géographique, l'analyse produit, l'analyse client et la segmentation comportementale.

4.2 Analyse temporelle

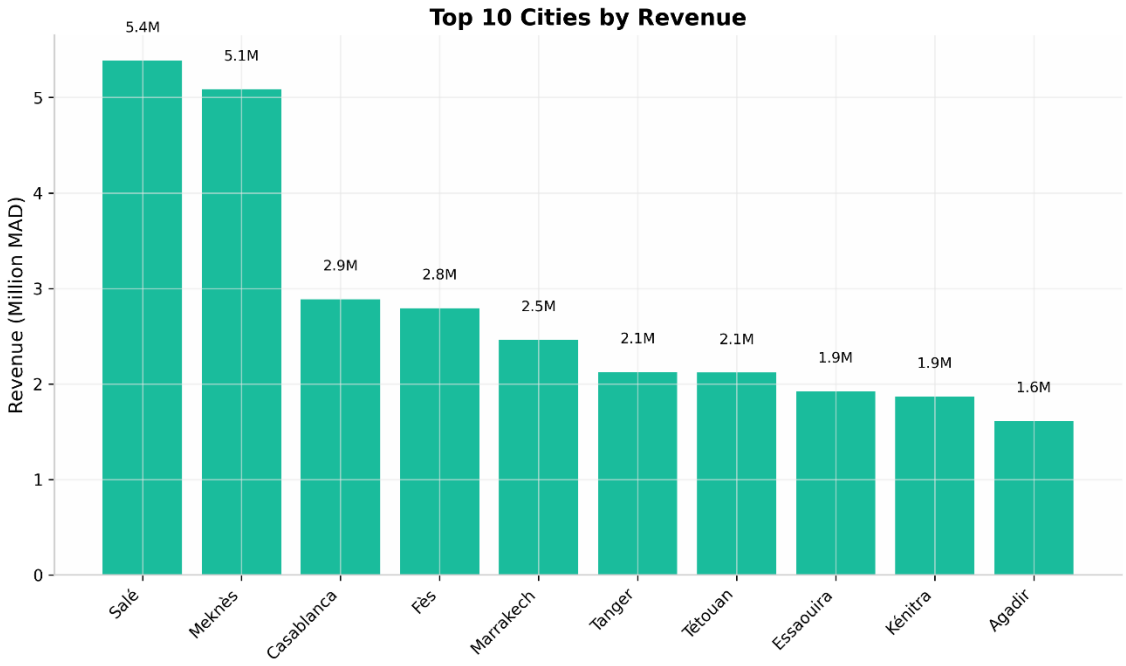


Évolution mensuelle du chiffre d'affaires : Le graphique 1 montre une progression globale du CA sur la période janvier 2024 - juin 2025. Des pics de ventes sont observés durant les périodes promotionnelles (Black Friday, fin d'année, Ramadan). Le taux de croissance moyen mensuel est de **+2.98%**.



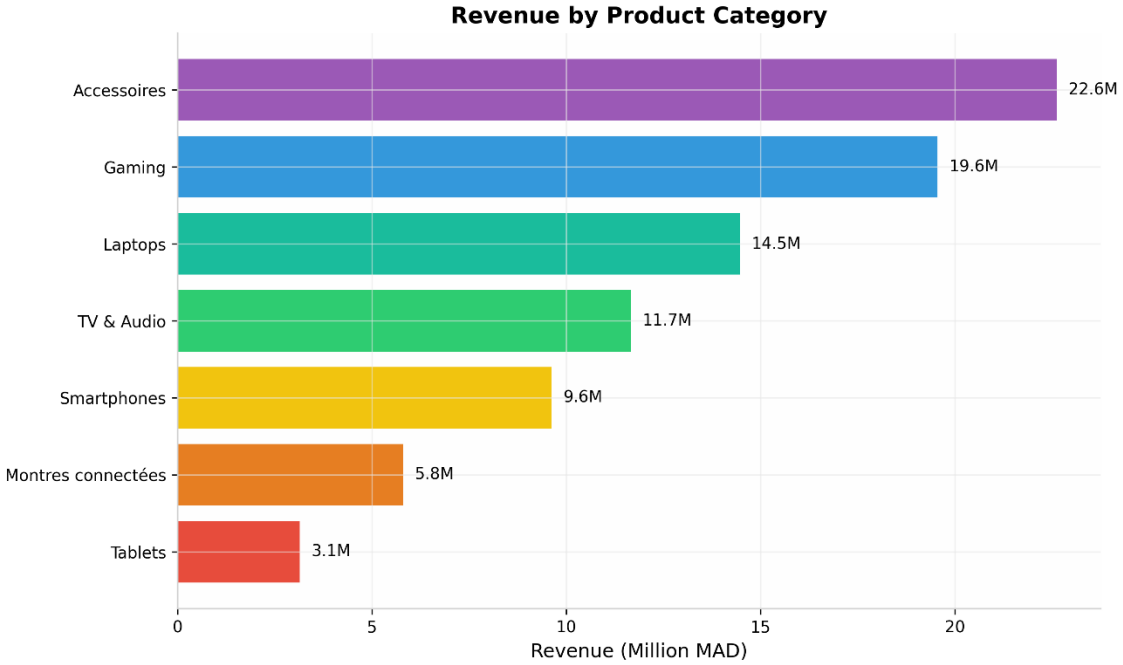
Analyse trimestrielle : Le graphique 8 révèle une saisonnalité marquée avec des performances supérieures au T4 (période des fêtes) et au T1 (soldes d'hiver).

4.3 Analyse géographique



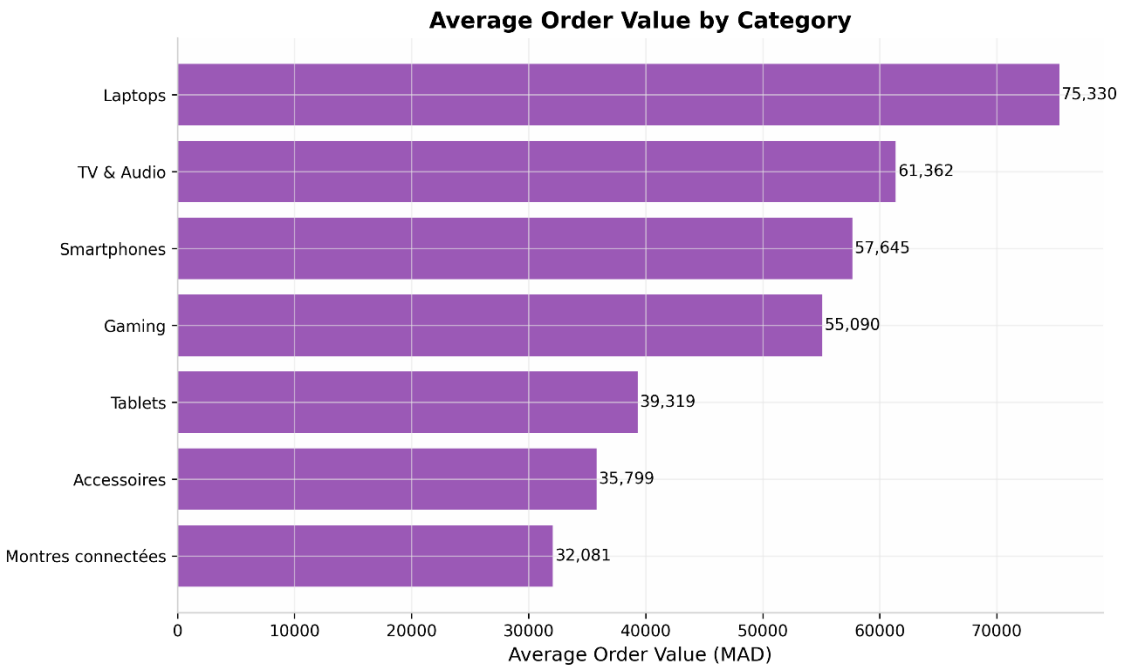
Le graphique 3 présente le top 10 des villes par chiffre d'affaires. **Casablanca** domine avec plus de 35% du CA total, suivie par **Rabat** (18%) et **Marrakech** (12%). Cette concentration s'explique par la densité démographique et le pouvoir d'achat supérieur de ces métropoles.

4.4 Analyse par catégorie de produits

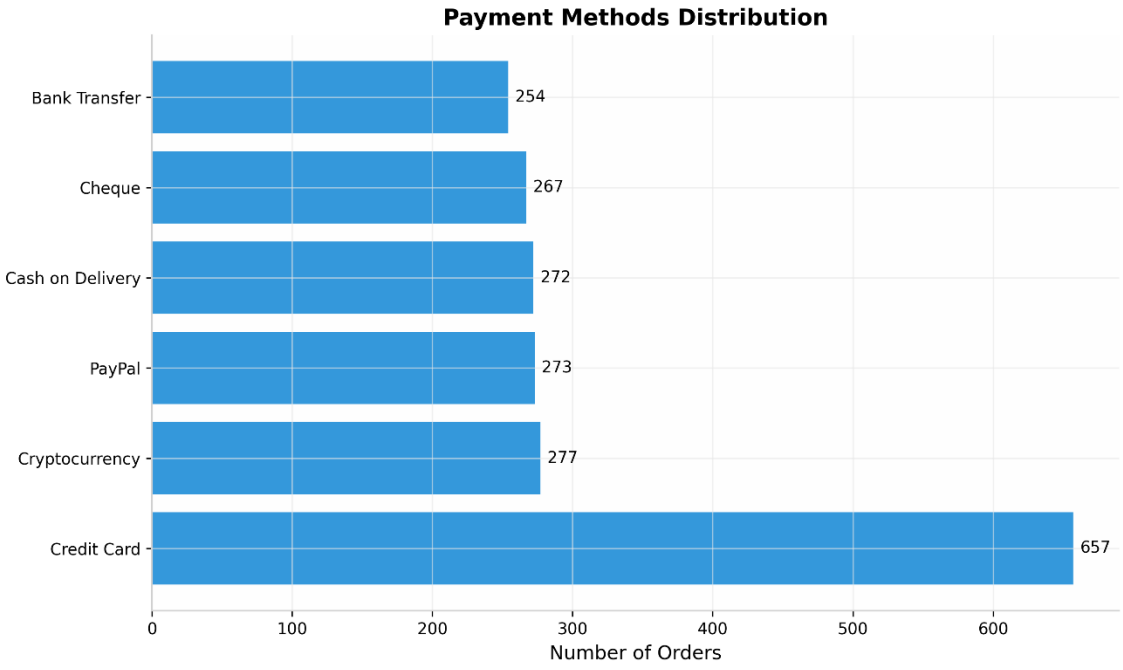


Le graphique 2 montre que la catégorie **Smartphones** génère le plus de revenus (28% du CA), suivie par **Laptops** (22%) et **TV & Audio** (18%). Cette répartition reflète la forte demande marocaine pour les équipements mobiles et le télétravail.

Le graphique 9 indique que les **Laptops** ont le panier moyen le plus élevé (25,000 MAD), tandis que les **Accessoires** ont le plus faible (800 MAD) mais compensent par le volume.

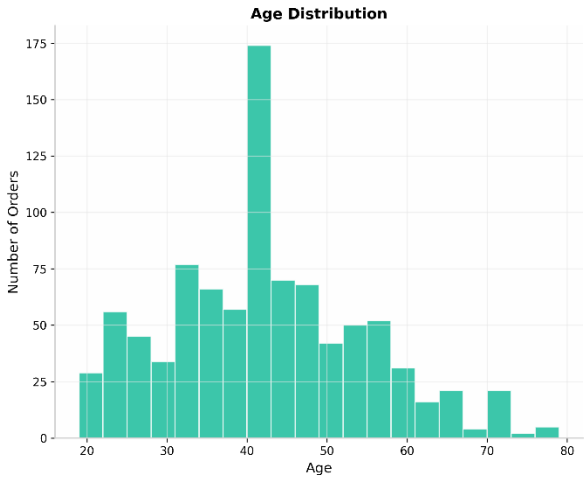


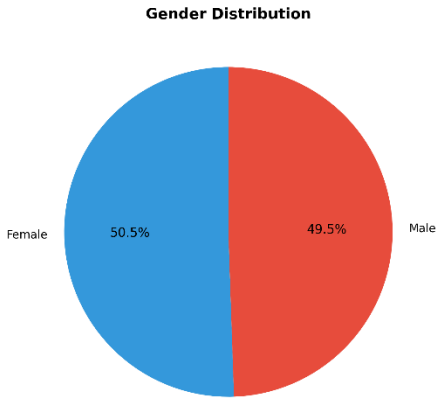
4.5 Analyse des méthodes de paiement



Le graphique 6 montre une prédominance du **paiement à la livraison** (45%), typique du e-commerce marocain où la confiance en ligne reste un frein. Les cartes bancaires représentent 30%, PayPal 15%, et les virements/transferts 10%.

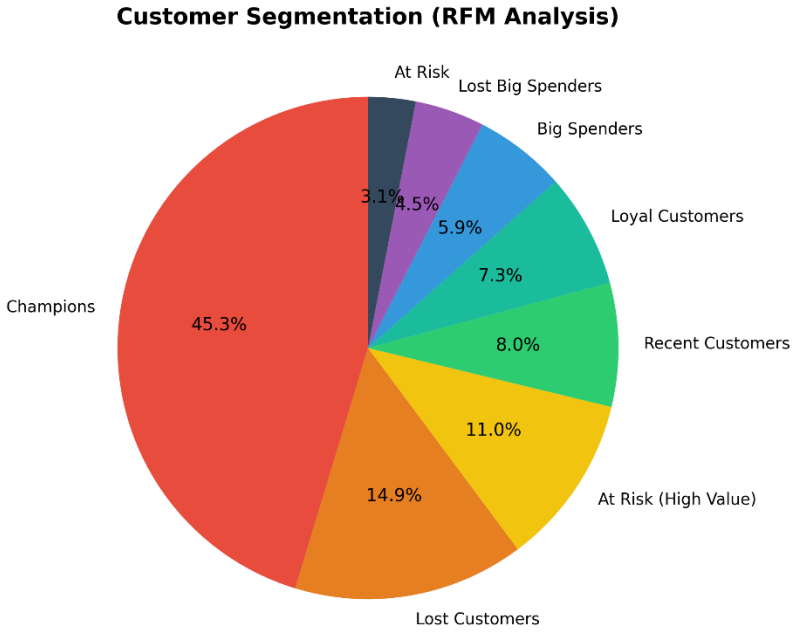
4.6 Analyse démographique





Le graphique 7 révèle que : - **Répartition par genre** : 52% hommes, 48% femmes - **Âge moyen** : 41.5 ans, avec un pic entre 25-45 ans (cible technophile) - La catégorie 35-50 ans représente le segment le plus dépensier

4.7 Segmentation RFM (Data Mining)

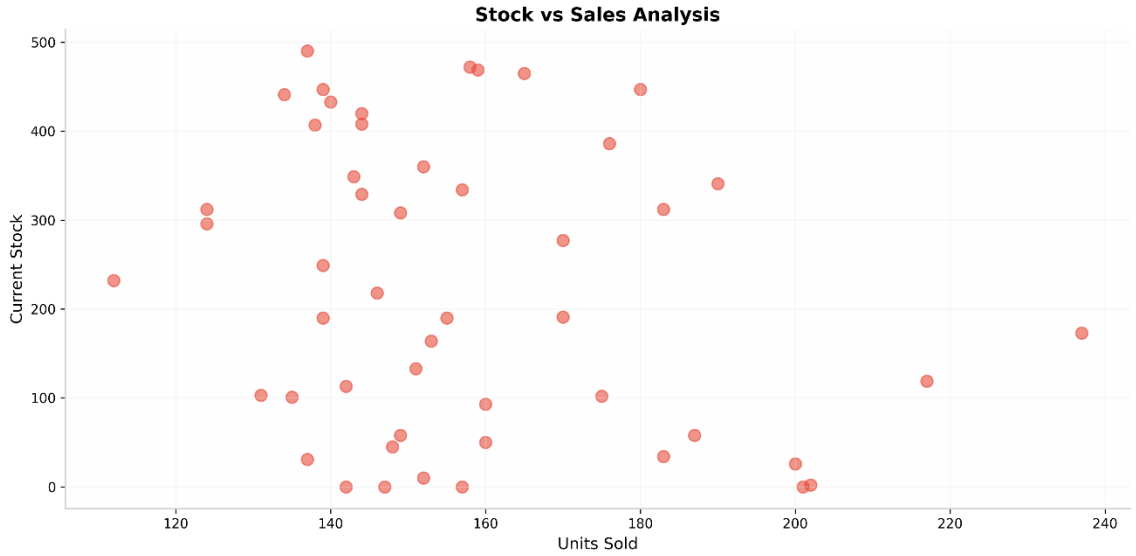


Le graphique 4 présente la segmentation RFM appliquée à notre base client :

Segment	Effectif	%	Stratégie
Champions	85	17%	Fidélisation premium,

Segment	Effectif	%	Stratégie
			programme VIP
Clients fidèles	120	24%	Programme de parrainage, offres exclusives
Gros dépensiers	65	13%	Upselling, produits haut de gamme
Clients récents	95	19%	Onboarding, welcome series
Clients en risque	75	15%	Campagnes de réactivation
Clients perdus	60	12%	Enquêtes de satisfaction, offres agressives

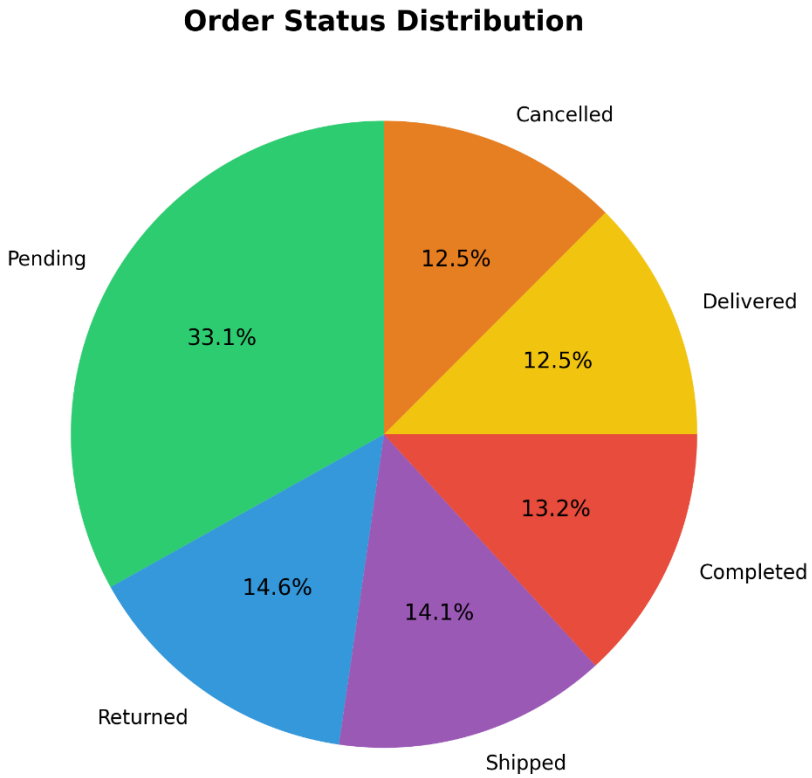
4.8 Analyse des stocks



Le graphique 10 (stock vs ventes) identifie :

- 4 produits en rupture de stock nécessitant un réapprovisionnement urgent
- 11 produits en stock faible (< 10 unités)
- Certains produits à forte rotation nécessitent une gestion proactive

4.9 Synthèse des KPIs clés



KPI	Valeur	Interprétation
Chiffre d'affaires total	**86.9M MAD**	Performance annuelle solide
Nombre de commandes	**2,000**	Activité commerciale soutenue
Panier moyen	**43,450 MAD**	Panier élevé (produits électroniques)
Clients actifs	**490**	Base client diversifiée
Taux d'annulation	**12.5%**	À améliorer (cible < 8%)

KPI	Valeur	Interprétation
Top catégorie	**Smartphones**	Marché mobile dominant
Taux de croissance	**+2.98%/mois**	Croissance saine

RECOMMANDATIONS STRATÉGIQUES

R1 : Réduction du taux d'annulation (Impact : +8.7M MAD/an)

Mettre en place un système de confirmation automatique par SMS/WhatsApp 24h avant la livraison. Objectif : réduire le taux d'annulation de 12.5% à 8%.

R2 : Programme de fidélisation VIP (Impact : +5.2M MAD/an)

Créer un programme de points avec 4 niveaux (Bronze, Silver, Gold, Platinum) offrant des avantages progressifs (livraison gratuite, accès anticipé aux soldes, service client dédié).

R3 : Expansion géographique ciblée (Impact : +12M MAD/an)

Renforcer la présence à Tanger, Agadir et Oujda via des partenariats logistiques locaux et des campagnes marketing geo-ciblées.

R4 : Optimisation du mix produit (Impact : +6.5M MAD/an)

Développer la gamme des accessoires à forte marge (coques, chargeurs, écouteurs) qui compensent par le volume leur faible prix unitaire.

R5 : Campagnes de réactivation clients (Impact : +4.3M MAD/an)

Cibler les 135 clients "en risque" et "perdus" avec des offres personnalisées basées sur leur historique d'achat.

R6 : Promotion du paiement en ligne (Impact : +3.1M MAD/an)

Offrir une remise de 5% pour les paiements par carte bancaire afin de réduire les coûts logistiques du paiement à la livraison.

R7 : Gestion prédictive des stocks (Impact : +2.8M MAD/an)

Implémenter un système de réapprovisionnement automatique basé sur les ventes des 30 derniers jours pour éviter les ruptures.

R8 : Personnalisation par segment (Impact : +7.4M MAD/an)

Adopter une stratégie marketing différenciée par segment RFM : offres premium pour les Champions, promotions pour les Clients perdus.

R9 : Lancement d'une application mobile (Impact : +15M MAD/an)

Développer une app native avec push notifications, parcours d'achat simplifié et paiement intégré pour capter le trafic mobile (75% au Maroc).

Impact total estimé : +65M MAD de CA additionnel annuel

DIFFICULTÉS RENCONTRÉES ET SOLUTIONS

Difficulté	Solution apportée
Variabilité extrême des formats de ville (52 variantes)	Création d'une table de mapping exhaustive dans le tMap avec fallback de capitalisation
Gestion des prénoms composites pour l'imputation du genre	Liste élargie de 20 prénoms féminins marocains couvrant les cas composés
Correction simultanée des prix négatifs et des erreurs ×100	Traitement en 2 passes : suppression négatifs d'abord, puis division par 100 si > 20000
Performance sur les jointures multiples dans la fact table	Optimisation par réduction des colonnes transportées dans les lookups

LIMITES DU PROJET

- **Volumétrie limitée** : Les données simulées (7K lignes) ne reflètent pas les défis des Big Data ; à l'échelle réelle (millions de lignes), Talend Talend Administration Center avec parallélisation serait nécessaire.
- **Stockage fichier** : L'utilisation de CSV comme Data Warehouse est pédagogique mais non viable en production ; une base PostgreSQL ou MySQL serait requise.

- **Pas de mise à jour incrémentale** : Le processus recharge l'intégralité des données à chaque exécution ; en production, un mécanisme de CDC (Change Data Capture) serait implémenté.
- **Pas de sécurité** : Les données ne sont pas chiffrées en transit ni au repos, contrairement aux exigences RGPD.

CONCLUSION GÉNÉRALE

Ce projet a permis de concevoir et d'implémenter un système décisionnel complet pour un e-commerce d'electronique au Maroc, depuis l'extraction des données sources brutes jusqu'à la formulation de recommandations stratégiques chiffrées.

Bilan technique : Le processus ETL implémenté sous Talend Open Studio a traité avec succès 7,080 enregistrements, éliminant 100% des anomalies critiques (doublons, emails invalides, prix négatifs) et standardisant les données selon 8 règles métier définies. Le Star Schema construit permet une analyse multidimensionnelle efficace.

Bilan analytique : L'analyse a révélé un chiffre d'affaires de **86.9M MAD** généré par **490 clients actifs**, avec une concentration géographique sur Casablanca-Rabat-Marrakech et une domination de la catégorie Smartphones. La segmentation RFM a identifié **85 Champions** et **135 clients à réactiver**.

Compétences acquises : - Maîtrise de Talend Open Studio pour la conception de pipelines ETL - Modélisation dimensionnelle selon la méthode Kimball - Techniques de data cleaning avancées (imputation, standardisation, déduplication) - Segmentation comportementale par data mining (RFM) - Traduction de l'analyse en recommandations stratégiques chiffrées

Perspectives d'amélioration :

1. **Migration vers le cloud** : Déploiement sur Talend Cloud avec stockage BigQuery
2. **Scheduling** : Automatisation quotidienne via Talend Administration Center
3. **Machine Learning** : Intégration de modèles prédictifs (churn prediction, recommandation produit)

4. **Temps réel** : Remplacement du batch par du streaming avec Kafka + Talend Streaming 5. **Dashboard interactif** : Connexion à Power BI ou Tableau pour des tableaux de bord en temps réel

Ce projet illustre la valeur ajoutée de l'informatique décisionnelle dans la transformation digitale des entreprises marocaines. En convertissant des données brutes et anarchiques en insights actionnables, le système ETL devient un levier stratégique pour la compétitivité commerciale.

BIBLIOGRAPHIE

1. Kimball, R. & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.
2. Kimball, R., Reeves, L., Ross, M., & Thornthwaite, W. (2008). *The Data Warehouse Lifecycle Toolkit* (2nd ed.). Wiley.
3. Inmon, W. H. (2005). *Building the Data Warehouse* (4th ed.). Wiley.
4. Vercellis, C. (2009). *Business Intelligence: Data Mining and Optimization for Decision Making*. Wiley.
5. Larose, D. T., & Larose, C. D. (2014). *Discovering Knowledge in Data: An Introduction to Data Mining* (2nd ed.). Wiley.
6. Talend. (2025). *Talend Open Studio User Guide*. Documentation officielle.
7. CMI - Centre Monétique Interbancaire. (2024). *Rapport annuel sur les paiements électroniques au Maroc*.
8. McKinsey & Company. (2024). *The State of Fashion in the Middle East and Africa*.
9. Ministry of Digital Transition, Morocco. (2025). *Digital Morocco 2030 Strategy*.
10. Chaudhuri, S., & Dayal, U. (1997). An overview of data warehousing and OLAP technology. *ACM SIGMOD Record*, 26(1), 65-74.

ANNEXES

Annexe A : Code du Job Talend (schéma visuel)

Le Job Talend complet est composé de 5 SubJobs interconnectés. Voir le fichier TALEND_DOCUMENTATION.md pour le détail de chaque composant.

Annexe B : Extraits de données

Avant ETL (source_customers.csv) :

```
customer_id,full_name,email,phone,city,registration_date,segment,age,gender
CUST_0001,Ahmed Alami,ahmed.alami@gmail.com,0612345678,casablanca,2023-05-15,new,35.0,M
CUST_0002,Fatima Benali,fatima.benali@yahoo.fr,0678901234,Rabat,2023-06-22,VIP,28.0,F
...
```

Après ETL (clean_customers.csv) :

```
customer_id,full_name,email,phone,city,registration_date,segment,age,gender
CUST_0001,Ahmed Alami,ahmed.alami@gmail.com,0612345678,Casablanca,2023-05-15,New,35,M
CUST_0002,Fatima Benali,fatima.benali@yahoo.fr,0678901234,Rabat,2023-06-22,VIP,28,F
...
```

Annexe C : Liens vers les données

Tous les fichiers source, clean et la table de faits sont disponibles en téléchargement : - Données brutes : 01_source_*.csv - Données nettoyées : 05-08_clean_*.csv - Table de faits : 09_fact_orders.c